

Otimização Topológica de Redes IIoT

para Monitoramento Preditivo em Ambientes Industriais

Uma Abordagem Baseada em Algoritmos Genéticos

Disciplina: DCC606 – Análise de Algoritmos | UFRR 2026

Referências: [1] Janikow & Clair, 1995 · [2] Li et al., 2009 · [3] Marks, 2010 · [4] Cormen et al., 2009

Motivação e Problema

Ambiente Hostil

Estruturas metálicas, paredes de concreto e máquinas criam zonas de sombra que bloqueiam sinais Wi-Fi e BLE, tornando o modelo de disco unitário insuficiente.

Restrição Energética

Sensores ESP32 operam com bateria. Distância excessiva ao gateway força aumento de potência TX, reduzindo drasticamente a vida útil operacional.

Explosão Combinatória

Com $m=15$ candidatos: $2^{15} = 32.768$ subconjuntos $\times$ espaço contínuo de coordenadas 3D. Busca exaustiva é intratável para escala industrial.

Classificação: variante NP-difícil do Facility Location Problem combinado com o Maximum Coverage Problem

Fundamentação Teórica

Algoritmos Genéticos

Genótipo vs Fenótipo: cromossomo misto (binário + real) decodificado em topologia física de rede.

Pressão de Seleção: controla exploração vs exploração. Torneio = $O(1)$; Roleta = $O(N)$.

Elitismo: top-k sobrevivem intactos garantindo monotonia crescente da aptidão.

Mutação Gaussiana: perturbações $N(0, \sigma)$ nas coordenadas contínuas mantêm diversidade.

Redes IIoT / WSN

MCDS (NP-difícil): menor conjunto de gateways que domina toda a rede — fundamenta a NP-dificuldade do problema.

Modelo Log-Distância: $P_{loss} = PL_0 + 10\gamma \cdot \log_{10}(d/d_0) + X_\sigma$ com $\gamma=2,7$ para ambientes industriais.

Trade-offs Multiobjetivo: cobertura $\times$ vida útil $\times$ conectividade são conflitantes — requerem abordagem evolutiva.

qsort $O(N \log N)$: ordenação por aptidão a cada geração usa o algoritmo heapsort/mergesort do Cormen.

Formulação Matemática do Problema

Cromossomo Misto

$x = (a_1, \dots, a_{15}, (x_1, y_1, z_1), \dots, (x_{15}, y_{15}, z_{15}))$
 $a_j \in \{0, 1\}$ — ativar gateway j ?
 $(x_j, y_j, z_j) \in \mathbb{R}^3$ — coordenadas refinadas
Tamanho: 428 bytes/cromossomo

Modelo Log-Distância

$P_{loss}(d) = PL_0 + 10 \cdot \gamma \cdot \log_{10}(d/d_0) + X_\sigma$
 $RSSI = P_{TX} - P_{loss} - A_{obs}$
 $\gamma = 2,7 \mid d_0 = 1m \mid PL_0 = 40dB$
 $P_{TX} = 20dBm \mid RSSI_{min} = -90dBm$
 A_{obs} : Liang-Barsky ($O(1)$ /obstáculo)

Função de Aptidão Multiobjetivo

$\max F(x) = 0,50 \cdot \mathbb{L}(\text{vida útil}) - 0,30 \cdot D(\text{latência}) + 0,20 \cdot R(\text{redundância}) - \varphi_{cob} - \varphi_{bud}$
 $\varphi_{cob} = 2,0 \cdot (1 - \rho_{cob}) \mid \varphi_{bud} = 0,5 \cdot \max(0, |G^*| - 5) \mid \text{Restrições: } RSSI \geq -90dBm \text{ e } |G^*| \leq 5$

C1: $\forall s_i \in S, \exists g_j \in G^* : RSSI(s_i, g_j) \geq -90 \text{ dBm}$ (hard) C2: $|G^*| \leq M_{max} = 5$ (hard) C3: posição $\in$ domínio $[0, 100]^2 \times [2, 10]$

Implementação Computacional — C99

Módulo	Funções Principais	Responsabilidade
Ambiente	setup_environment()	Sensores, candidatos, obstáculos
Propagação	compute_rssi(), segment_hits_obstacle()	Eq.4 + Liang-Barsky $O(1)$
Aptidão	eval_fitness(), compute_lifetime(), compute_latency()	Eq.5 multiobjetivo $O(n \cdot m)$
Seleção	sel_tournament() $O(k)$ / sel_roulette() $O(N)$	Torneio vs Roleta
Variação	crossover_1pt(), crossover_2pt(), mutate(), repair_budget()	Cruzamento + mutação + reparo
Evolução	init_population(), evolve_one_generation(), run_experiment()	Ciclo geracional completo

Análise de Complexidade Assintótica

Função	Tempo	Espaço
segment_hits_obstacle()	$O(1)$	$O(1)$
compute_rssi()	$O(N_{\text{obs}}) = O(1)$	$O(1)$
eval_fitness()	$O(n \cdot m)$	$O(1)$
sel_tournament()	$O(k_T) = O(1)$	$O(1)$
sel_roulette()	$O(N)$	$O(N)$
crossover_1pt / 2pt()	$O(m)$	$O(m)$
mutate()	$O(m)$	$O(1)$
repair_budget()	$O(m)$	$O(m)$
evolve_one_generation() torneio	$O(N \cdot n \cdot m)$	$O(N \cdot m)$
evolve_one_generation() roleta	$O(N^2 + N \cdot n \cdot m)$	$O(N \cdot m)$
run_experiment() TOTAL	$O(G \cdot N \cdot n \cdot m)$	$O(N \cdot m)$

AG (meta-heurística)

$$\begin{aligned} &O(G \cdot N \cdot n \cdot m) \\ &= O(600 \times 120 \times 20 \times 15) \\ &\approx 21,6 \text{ M operações} \end{aligned}$$

Força Bruta

$$\begin{aligned} &O(2^m \cdot n) \\ &= O(2^{15} \times 20) \\ &\approx 655K \times \text{busca contínua} \end{aligned}$$

Operadores de Seleção: Torneio vs Roleta

TORNEIO ESTOCÁSTICO $k=5$

Complexidade: $O(k) = O(1)$ por seleção

Pressão: moderada e controlável

Escala de aptidão: independente e robusta

Diversidade: mantida por mais gerações

Risco: convergência mais lenta

Indicado para: espaços multimodais com múltiplos ótimos locais criados por obstáculos industriais.

ROLETA VICIADA POR APTIDÃO

Complexidade: $O(N)$ por seleção

Pressão: proporcional à aptidão

Escala de aptidão: sensível, pode distorcer

Convergência: inicial rápida

Risco: crowding, pode haver homogeneização precoce

Indicado para: instâncias com poucos ótimos locais onde explorar boas soluções iniciais é vantajoso.

Ambos implementados em `iiot_ga_1.c` — comparação experimental exportada em `hist_torneio.csv` e `hist_roleta.csv`

Ambiente de Simulação e Resultados

Parâmetro	Valor
Dimensões da planta	100 × 100 × 10 m
Sensores fixos (n)	20 — grade 5×4
Candidatos a gateway (m)	15 posições
Orçamento máximo (M _{max})	5 gateways
Obstáculos industriais	4 (2 estruturas + 2 paredes)
Potência TX (ESP32)	20 dBm
Limiar RSSI mínimo	-90 dBm
Expoente de atenuação (γ)	2,7
Bateria / Vida máxima	5.000 mAh / 8.760 h
Gerações / População	600 / 120 indivíduos

Resultados Comparativos

Métrica	Torneio	Roleta
Melhor F _{best}	0,17009	0,16932
Convergência g*	42	145
Gateways G*	5,0	5,0
Cobertura p _{cob}	100,0%	100,0%
Vida útil (h)	120,8	120,3
Redundância	4,85	4,84
Tempo CPU (ms)	1350	1350

Aplicação Prática e Visualização de Resultados

1

Levantamento

Mapear coordenadas dos pontos de monitoramento obrigatórios e posições candidatas permitidas pela infraestrutura elétrica.

2

Configuração

Inserir parâmetros em `setup_environment()`. Compilar com `gcc -O2 -lm`. Execução em segundos para $n=20$, $m=15$.

3

Análise

Avaliar mapa ASCII, tabelas de RSSI por par sensor-gateway e métricas de rede. Plotar curvas de convergência com `plot_resultados.py`.

4

Implantação

Instalar gateways nas coordenadas (x^*, y^*, z^*) . RSSI ≥ -90 dBm garante conexão estável de todos os sensores ESP32.

Escalabilidade

$O(G \cdot N \cdot n \cdot m)$ permanece tratável para $n > 100$ sensores e $m > 50$ candidatos com ajuste de N e $G_{\max}$. Marks valida AGs com 200 sensores em hardware convencional. Modularidade do código permite adaptação sem reescrita.

`plot_resultados.py` — 4 Gráficos


G1: Curva de convergência — melhor aptidão/geração

G2: Evolução da aptidão média da população


G3: Comparativo sobrepostos (torneio vs roleta)

G4: Ganho marginal ΔF por geração (janela 30)


Convergência — Melhor Aptidão




Aptidão Média da População



Comparativo Geral — Torneio vs Roleta



Ganho Marginal por Geração



Referências Bibliográficas

- Janikow, C.; Clair, D. Simulating nature's methods of evolving the best design solution. IEEE Potentials, v.14, n.1, 1995.
- Li, J. et al. Connectivity, coverage and placement in WSN. Sensors, v.9, n.10, 2009. DOI: 10.3390/s91007664
- Marks, M. A survey of multi-objective deployment in WSN. JTIT, n.3, 2010.
- Cormen, T. H. et al. Introduction to Algorithms. 3.^a ed. MIT Press, 2009.