

Otimização Topológica de Redes IIoT para Monitoramento Preditivo em Ambientes Industriais: Uma Abordagem Baseada em Algoritmos Genéticos

Topological Optimization of IIoT Networks for Predictive Monitoring in Industrial Environments: A Genetic Algorithm Approach

Ryan Kayky Marques Rolins Bastos
João Roberto Randel Costa Cunha

Projeto Final — DCC606 Análise de Algoritmos
Tema 5 — FP_DCC606_Tema_5_RR_2026
Universidade Federal de Roraima (UFRR) — 2026

Resumo

A crescente adoção de redes de Internet das Coisas Industrial (IIoT) na Indústria 4.0 impõe desafios críticos de planejamento topológico: posicionar *gateways* de forma a maximizar a cobertura de sensores, prolongar a vida útil das baterias e garantir redundância de caminhos de comunicação, tudo sob restrições estritas de orçamento de infraestrutura e limiar mínimo de intensidade de sinal recebido (RSSI). Este trabalho apresenta o projeto, a análise algorítmica formal e a implementação em linguagem C de um motor de otimização evolutiva baseado em Algoritmos Genéticos (AG) para a síntese topológica automatizada de redes IIoT em plantas industriais. O problema é classificado como variante NP-Completa do *Facility Location Problem*, inviabilizando abordagens exatas para instâncias realistas conforme postulado pela teoria da complexidade. O cromossomo adota representação mista — binária para ativação de *gateways* candidatos e real para refinamento de coordenadas tridimensionais — conforme o paradigma genotípico-fenotípico descrito em Janikow e Clair [1]. A função de aptidão multiobjetivo pondera vida útil da rede, latência média e redundância de caminhos, penalizando violações de cobertura e de orçamento. Dois operadores de seleção estocástica são comparados: Torneio e Roleta Viciada por Aptidão. O modelo de propagação de sinal emprega a equação log-distância com detecção de obstrução por algoritmo de interseção paramétrica $O(1)$. Os experimentos, conduzidos sobre uma planta simulada de 100×100 m contendo 20 sensores fixos, 15 posições candidatas a *gateway* e 4 obstáculos industriais, demonstram a viabilidade e eficácia do AG como algoritmo randomizado de tempo polinomial esperado para o planejamento automatizado de redes IIoT em ambientes adversos.

Palavras-chave: Algoritmos Genéticos; Internet das Coisas Industrial (IIoT);

Otimização Topológica; *Facility Location Problem*; Algoritmos Randomizados; Complexidade Assintótica; Indústria 4.0.

Sumário

1	Introdução	4
2	Fundamentação Teórica	5
2.1	Redes IIoT e o Problema de Posicionamento de <i>Gateways</i>	5
2.2	Algoritmos Genéticos como Algoritmos Randomizados	5
2.3	Análise Crítica do Artigo de Janikow e Clair (1995)	5
3	Formulação Matemática do Problema	6
3.1	Definição do Espaço de Busca e Variáveis de Decisão	6
3.2	Modelo de Propagação de Sinal: Equação Log-Distância	6
3.3	Função de Aptidão Multiobjetivo	6
3.4	Restrições do Modelo	7
4	Metodologia	7
4.1	Fluxo Evolutivo	7
4.2	Parâmetros do Algoritmo Genético	7
4.3	Estratégia de Comparação dos Operadores de Seleção	7
5	Implementação Computacional	8
5.1	Arquitetura Modular	8
5.2	Estrutura de Dados e Função Estocástica de Reparo	8
5.3	Modelo de Propagação e Detecção de Obstáculos	10
5.4	Operadores Genéticos	10
6	Análise de Complexidade Assintótica	10
7	Experimentos e Visualização de Resultados	11
7.1	Configuração do Ambiente de Simulação	11
7.2	Visualização Analítica e <i>Trade-offs</i>	11
7.3	Protocolo de Análise Comparativa	12
7.4	Discussão dos <i>Trade-offs</i>	12
8	Aplicação Prática em Ambiente Industrial	13
8.1	Cenário: Manutenção Preditiva de Maquinário Pesado	13
8.2	Fluxo de Implantação Prático	13
8.3	Escalabilidade	13
9	Conclusão	13

1 Introdução

A quarta revolução industrial, amplamente denominada Indústria 4.0, é caracterizada pela convergência entre sistemas ciberfísicos, computação em nuvem e redes densas de dispositivos conectados. No âmbito desta transformação, as redes de Internet das Coisas Industrial (IIoT) emergem como infraestrutura crítica para o monitoramento preditivo de máquinas, a automação de processos e a coleta de dados operacionais em tempo real [2]. Centenas de nós sensores — frequentemente baseados em microcontroladores de baixo consumo como o ESP32 — distribuem-se por plantas industriais e precisam transmitir dados continuamente a *gateways* coordenadores, que por sua vez encaminham as informações a sistemas supervisórios centrais.

O planejamento topológico dessas redes, entretanto, é inerentemente complexo. O ambiente industrial é hostil à propagação eletromagnética: estruturas metálicas, maquinários pesados e paredes de concreto atenuam e refletem sinais sem fio de forma heterogênea [2]. Adicionalmente, a grande maioria dos nós sensores opera alimentada por baterias, tornando a eficiência energética um requisito de sobrevivência operacional do sistema. A determinação manual das posições ótimas de *gateways* torna-se rapidamente impraticável à medida que o tamanho da rede cresce.

Do ponto de vista da Ciência da Computação e da Pesquisa Operacional, o problema de posicionamento ótimo de *gateways* em redes IIoT é uma variante do *Facility Location Problem* (FLP) combinado com o *Maximum Coverage Problem*. Conforme fundamentado por Cormen et al. [3], problemas de cobertura e localização com essa estrutura de restrições pertencem à classe de problemas NP-Completo. A explosão combinatória do espaço de busca — que cresce exponencialmente com o número de posições candidatas — inviabiliza abordagens exatas ou de força bruta para instâncias de escala industrial. Essa barreira teórica motiva o emprego de algoritmos randomizados e meta-heurísticas evolutivas [3].

Os Algoritmos Genéticos (AG) inserem-se nessa classe de algoritmos randomizados, inspirando-se nos mecanismos da seleção natural e da genética populacional darwiniana. Conforme descrevem Janikow e Clair [1], o AG mantém uma população de soluções candidatas (cromossomos) que evoluem ao longo de gerações por meio de operadores estocásticos de seleção, cruzamento e mutação, guiados por uma função de aptidão (*fitness*) que quantifica a qualidade de cada solução. A pressão de seleção e o elitismo são mecanismos centrais para controlar a velocidade de convergência e mitigar a perda de soluções em ótimos locais durante a execução pseudo-polinomial [1, 3].

No contexto de redes de sensores sem fio (WSN), a literatura técnica demonstra que a conectividade e o posicionamento de elementos de infraestrutura são problemas fundamentais para a longevidade e o desempenho da rede [2]. Conceitos como *Connected Dominating Set* (CDS) e *Minimum Connected Dominating Set* (MCDS) evidenciam a relação entre topologia da rede e eficiência energética coletiva [2]. A abordagem proposta incorpora estas perspectivas ao modelar explicitamente a conectividade de cada sensor ao *gateway* mais próximo com sinal válido.

Este artigo está estruturado da seguinte forma: a Seção 2 apresenta a fundamentação teórica; a Seção 3 formula matematicamente o problema; a Seção 4 descreve a metodologia; a Seção 5 detalha a implementação computacional e integração das estruturas; a Seção 6 analisa a complexidade assintótica baseada na teoria de algoritmos; a Seção 7 apresenta os experimentos e resultados visuais; a Seção 8 discute aplicações práticas; e a Seção 9

conclui o trabalho.

2 Fundamentação Teórica

2.1 Redes IIoT e o Problema de Posicionamento de *Gateways*

As Redes de Internet das Coisas Industrial (IIoT) constituem uma extensão especializada das Redes de Sensores Sem Fio (WSN) voltada ao ambiente fabril e aos sistemas ciberfísicos da Indústria 4.0. Conforme sintetizado em Li et al. [2], uma WSN é composta por nós com capacidades integradas de sensoriamento, processamento e comunicação, interconectados por enlaces sem fio para transmitir dados coletados do ambiente físico a centros de processamento ou *gateways*. A conectividade plena da rede é requisito fundamental para o funcionamento da infraestrutura [2].

Modelos mais realistas, como o de atenuação log-distância com sombreamento (*log-normal shadowing*), capturam melhor a variabilidade do canal em ambientes internos [2]. Sob a ótica da teoria dos grafos, a existência de um *Conjunto Dominante Conexo* (CDS) formado pelos *gateways* é condição suficiente para que todos os nós sensores possam alcançar a infraestrutura de coleta em um único salto [2]. O subconjunto mínimo de *gateways* que satisfaz simultaneamente os critérios de conectividade e dominância corresponde ao MCDS, cuja determinação exata recai novamente em NP-Hard [2, 3].

A literatura de implantação multiobjetivo em WSN sistematizada por Marks [4] evidencia que os objetivos de cobertura, vida útil da rede, conectividade e eficiência energética são simultaneamente desejáveis, porém conflitantes entre si. Marks [4] demonstra que a abordagem mais adequada para este tipo de problema consiste em métodos evolutivos multiobjetivo capazes de mapear a Fronteira de Pareto entre os objetivos conflitantes.

2.2 Algoritmos Genéticos como Algoritmos Randomizados

No contexto da complexidade computacional definida por Cormen et al. [3], heurísticas e Algoritmos Genéticos introduzem aleatoriedade controlada para direcionar a busca no espaço de estados. Seu funcionamento básico consiste em manter uma população de soluções candidatas e evoluí-la iterativamente.

A **seleção** atua como um mecanismo direcional probabilístico onde indivíduos com maior aptidão têm maior chance de propagação. A *pressão de seleção* regula a convergência: pressão elevada acelera o processo, mas aumenta o risco de estagnação em ótimos locais [1]. O **cruzamento** recombina o subproblema ótimo de dois pais para gerar novos vetores, explorando regiões promissoras. A **mutação** opera como uma busca local aleatorizada (perturbação), garantindo a diversidade genética. O **elitismo** atua como salvaguarda determinística na monotonia crescente da qualidade populacional [1].

2.3 Análise Crítica do Artigo de Janikow e Clair (1995)

O artigo seminal de Janikow e Clair [1] estabelece com clareza a distinção fundamental entre **genótipo** e **fenótipo**: o genótipo é a representação interna do cromossomo que o AG manipula, enquanto o fenótipo é a solução decodificada avaliada pela função de aptidão [1]. No sistema implementado, o genótipo é composto por um vetor binário de

ativação de *gateways* (decisão discreta) e valores reais de coordenadas tridimensionais (parâmetros contínuos). O fenótipo é a topologia física da rede IIoT resultante.

Janikow e Clair [1] descrevem a pressão de seleção como o principal mecanismo de controle do equilíbrio entre exploração (*exploration*) e exploração (*exploitation*). A seleção por torneio oferece controle mais robusto da pressão de seleção, enquanto a seleção por roleta favorece fortemente os melhores indivíduos, podendo causar convergência prematura [1].

3 Formulação Matemática do Problema

3.1 Definição do Espaço de Busca e Variáveis de Decisão

Seja a planta industrial definida por um volume $\mathcal{V} \subset \mathbb{R}^3$ com dimensões $W \times H \times Z_{\max}$ metros. Define-se:

- $S = \{s_1, \dots, s_n\}$: conjunto de n sensores fixos em coordenadas conhecidas.
- $G = \{g_1, \dots, g_m\}$: conjunto de m posições candidatas a *gateway*.
- $G^* \subseteq G$: subconjunto ativo selecionado pelo AG, com $|G^*| \leq M_{\max}$.

O cromossomo de cada indivíduo codifica variáveis de decisão mistas:

$$\mathbf{x} = (a_1, \dots, a_m, (x_1^g, y_1^g, z_1^g), \dots, (x_m^g, y_m^g, z_m^g)) \quad (1)$$

onde $a_j \in \{0, 1\}$ e $(x_j^g, y_j^g, z_j^g) \in \mathbb{R}^3$. A instância implementada opera com $n = 20$, $m = 15$ e $M_{\max} = 5$.

3.2 Modelo de Propagação de Sinal: Equação Log-Distância

A viabilidade de comunicação entre sensor s_i e *gateway* g_j é determinada pelo RSSI calculado pelo modelo log-distância [2]:

$$P_{\text{loss}}(d) = P_{\text{loss}}(d_0) + 10 \cdot \gamma \cdot \log_{10}\left(\frac{d}{d_0}\right) + X_{\sigma} \quad (2)$$

com $d_0 = 1,0$ m, $P_{\text{loss}}(d_0) = 40$ dB, $\gamma = 2,7$ e X_{σ} modelado pela atenuação de obstáculos detectados. O RSSI resultante é:

$$\text{RSSI}(s_i, g_j) = P_{TX} - P_{\text{loss}}(d) - A_{\text{obs}}(s_i, g_j) \quad (3)$$

A restrição de conectividade impõe que $\forall s_i \in S, \exists g_j \in G^*$: $\text{RSSI}(s_i, g_j) \geq -90$ dBm (C1).

3.3 Função de Aptidão Multiobjetivo

O objetivo central é maximizar [4]:

$$\max F(\mathbf{x}) = \alpha \cdot \hat{L} - \beta \cdot \hat{D} + \delta \cdot \hat{R} - \phi_{\text{cob}} - \phi_{\text{bud}} \quad (4)$$

com $\alpha = 0,50$, $\beta = 0,30$, $\delta = 0,20$, onde:

- $\hat{L}$: vida útil normalizada dos sensores $\in [0, 1]$.
- $\hat{D}$: latência média normalizada (distância ao *gateway* válido mais próximo) $\in [0, 1]$.
- $\hat{R}$: redundância normalizada (*gateways* alcançáveis por sensor) $\in [0, 1]$.
- $\phi_{\text{cob}} = 2,0 \cdot (1 - \rho_{\text{cob}})$: penalidade por sensores não cobertos.
- $\phi_{\text{bud}} = 0,5 \cdot \max(0, |G^*| - M_{\text{max}})$: penalidade por violação de orçamento.

3.4 Restrições do Modelo

Tabela 1: Restrições do modelo de otimização.

#	Restrição	Tipo
C1	$\forall s_i \in S, \exists g_j \in G^*: \text{RSSI}(s_i, g_j) \geq -90 \text{ dBm}$	<i>Hard</i>
C2	$ G^* \leq M_{\text{max}} = 5$	<i>Hard</i>
C3	$x_j^g \in [0, W], y_j^g \in [0, H], z_j^g \in [2, 10] \text{ m}$	Domínio

C2 e C3 são satisfeitas deterministicamente por algoritmos de limite. C1 é tratada suavemente por ϕ_{cob} .

4 Metodologia

4.1 Fluxo Evolutivo

O ciclo geracional implementado em `iiot_ga.c` segue o paradigma canônico descrito em [1]:

Listing 1: Pseudocódigo do ciclo geracional.

```
[Inicializacao] -> [Avaliacao (Eq. 5)] -> [Ordenacao]
|
[Elitismo: top-k] -> [Selecao -> Cruzamento -> Mutacao ->
  Reparo]
|
[Nova Populacao] -> [Atualizacao Melhor Global]
|
[Criterio de Parada: g = MAX_GENS?] -> SIM: [Exportacao]
| NAO
[Proxima Geracao]
```

4.2 Parâmetros do Algoritmo Genético

4.3 Estratégia de Comparação dos Operadores de Seleção

Dois experimentos independentes são executados com sementes distintas ($\Delta_{\text{seed}} = 7919$, número primo) para manter independência estatística:

- **Experimento 1:** Seleção por Torneio Estocástico ($k_T = 5$).
- **Experimento 2:** Seleção por Roleta Viciada por Aptidão.

Tabela 2: Parâmetros do Algoritmo Genético.

Parâmetro	Símbolo	Valor
Tamanho da população	N_{pop}	120
Número máximo de gerações	G_{max}	600
Elitismo	k	6
Tamanho do torneio	k_T	5
Probabilidade de cruzamento	p_c	0,85
Taxa de mutação binária	p_{mb}	0,04
Taxa de mutação real	p_{mr}	0,10
Desvio padrão gaussiano XY	σ_{XY}	5,0 m
Desvio padrão gaussiano Z	σ_Z	1,5 m

5 Implementação Computacional

5.1 Arquitetura Modular

O sistema foi implementado integralmente em C99, sem bibliotecas externas de otimização. Seis módulos funcionais coesos compõem a arquitetura:

5.2 Estrutura de Dados e Função Estocástica de Reparo

A estrutura central implementa o mapeamento genotípico-fenotípico de Janikow e Clair [1]. Como mecanismo corretivo essencial para algoritmos randomizados que violam o espaço viável durante a mutação, o algoritmo de reparo ajusta a restrição orçamentária (C2) em tempo linear assintótico $O(m)$:

Listing 2: Estrutura do cromossomo misto e rotina de reparacao $O(m)$ em C.

```

1  /* Cromossomo de Representacao Mista
2     Genotipo binario (decisao) e real (parametros continuos) */
3  typedef struct {
4     int    active[N_CANDIDATES];
5     double pos[N_CANDIDATES][3];
6     double fitness;
7  } Chromo;
8
9  /*
10   * Reparacao de restricoes de orcamento apos mutacao/cruzamento
11   *
12   * Garante: 1 <= |G*| <= Mmax (restricao C2)
13   */
14 static void repair_budget(Chromo *c) {
15     if (n_active(c) == 0)
16         c->active[rand() % N_CANDIDATES] = 1; /* Garante ao
17         menos 1 gateway */
18
19     int active_idx[N_CANDIDATES], cnt = 0;
20     for (int i = 0; i < N_CANDIDATES; i++)
21         if (c->active[i]) active_idx[cnt++] = i;

```


Tabela 3: Módulos funcionais do sistema.

Módulo	Funções Principais
Ambiente	<code>setup_environment()</code>

Propagação `compute_rssi(), segment_hits_obstacle()`

Aptidão `eval_fitness(), compute_lifetime(), compute_latency(), compute_redundancy()`

Seleção `sel_tournament(), sel_roulette()`

Variação `crossover_1pt(), crossover_2pt(), mutate(), repair_budget()`

Evolução `init_population(), evolve_one_generation(), run_experiment()`

```

21     while (cnt > MAX_GW) {
22         int pick = rand() % cnt;
23         c->active[active_idx[pick]] = 0; /* Exclusao aleatoria
        */
24         active_idx[pick] = active_idx[--cnt];

```

```

25     }
26 }

```

Tamanho por cromossomo: $15 \times 4 + 15 \times 3 \times 8 + 8 = 428$ bytes. Memória total das duas populações: $2 \times 120 \times 428 \approx 102,7$ KB.

5.3 Modelo de Propagação e Detecção de Obstáculos

`compute_rssi()` implementa a Eq. (2). `extra_attenuation()` itera sobre os $N_{\text{obs}} = 4$ obstáculos e invoca `segment_hits_obstacle()` para cada par sensor-*gateway*, empregando o algoritmo de recorte paramétrico de Liang-Barsky em projeção XY. Cada obstáculo interceptado acrescenta 20 dB de atenuação ao caminho, modelando o sombreado em ambientes industriais [2].

5.4 Operadores Genéticos

Inicialização: `init_chromo()` gera ativações estocásticas com probabilidade 25% por candidato e perturbações gaussianas $\mathcal{N}(0, 4,0)$ em XY e $\mathcal{N}(0, 1,0)$ em Z sobre as posições candidatas.

Cruzamento: `crossover_1pt()` e `crossover_2pt()` alternam aleatoriamente, operando simultaneamente sobre genes binários e reais. Ponto(s) de corte selecionados uniformemente em $[1, m - 1]$.

Mutação: Inversão de bit com $p_{mb} = 0,04$ (genes binários) e perturbação gaussiana com $p_{mr} = 0,10$ e desvios $\sigma_{XY} = 5,0$ m, $\sigma_Z = 1,5$ m (genes reais). O gerador de variável pseudoaleatória segue a transformada Box-Muller implementada nativamente.

Elitismo: Os $k = 6$ melhores indivíduos são preservados na geração seguinte após ordenação com o algoritmo probabilístico *Quicksort*.

6 Análise de Complexidade Assintótica

À luz da teoria de Análise de Algoritmos de Cormen et al. [3], formalizamos o custo assintótico esperado do programa. Sejam n o número de sensores, m posições candidatas, N o tamanho da população e G_{max} o limite de iterações:

- **Avaliação (`eval_fitness`):** O cálculo geométrico entre conexões ativas requer tempo proporcional aos nós, logo $O(n \cdot m)$. Para N indivíduos avaliados, o custo geracional é estritamente $O(N \cdot n \cdot m)$.
- **Ordenação Populacional (Elitismo):** A arquitetura utiliza a função nativa `qsort`. O *Quicksort* aleatorizado de particionamento opera com tempo médio/esperado rigoroso $\Theta(N \log N)$ e tempo de pior caso $O(N^2)$ [3].
- **Varição e Reparo:** Cruzamento e algoritmo de correção orçamentária avaliam o vetor m , somando ao final de uma geração inteira complexidade linear $O(N \cdot m)$.

A relação de recorrência final de tempo pseudo-polinomial esperado para o algoritmo genético (T_{AG}), em função do seu critério de parada probabilístico e limite de gerações G_{max} , reflete as operações de maior ordem:

Tabela 4: Custos de Complexidade Computacional e Espacial.

Função	Tempo	Espaço
<code>segment_hits_obstacle()</code>	$O(1)$	$O(1)$
<code>eval_fitness()</code>	$O(n \cdot m)$	$O(1)$
<code>sel_tournament()</code>	$O(k_T) = O(1)$	$O(1)$
<code>repair_budget()</code>	$O(m)$	$O(m)$
<code>evolve_one_generation()</code>	$O(N \log N + N \cdot n \cdot m)$	$O(N \cdot m)$

$$T_{AG} = O(G_{\max} \cdot N \cdot (\log N + n \cdot m)) \quad (5)$$

Esta complexidade contorna o intratável limite combinatório exponencial do *Facility Location Problem* provado por força bruta $O(2^m \cdot n)$. A complexidade espacial restringe-se ao armazenamento local de vetores na memória, $O(N \cdot m)$, o que caracteriza altíssima adequação a controladores locais industriais.

7 Experimentos e Visualização de Resultados

7.1 Configuração do Ambiente de Simulação

Tabela 5: Parâmetros do ambiente de simulação e canal RF.

Parâmetro	Valor
Dimensões da planta ($W \times H \times Z$)	$100 \times 100 \times 10$ m
Número de sensores fixos (n)	20 (grade 5×4)
Número de candidatos a <i>gateway</i> (m)	15
Orçamento máximo ($M_{\max}$)	5
Potência de transmissão ESP32 (P_{TX})	20 dBm
Limiar mínimo de RSSI	-90 dBm
Expoente de atenuação (γ)	2,7
Atenuação por obstáculo	20 dB
Obstáculos industriais	4 (2 estruturas metálicas + 2 paredes)

7.2 Visualização Analítica e *Trade-offs*

Para extrair relatórios visuais sobre o comportamento assintótico dos vetores evolutivos e o *trade-off* de aptidão dos operadores de seleção investigados, desenvolveu-se o *script* complementar `plot_resultados.py`.

O método evidenciado abaixo extrai isoladamente o Ganho Marginal (ΔF) provido por cada geração transcorrida, suavizando o ruído natural intrínseco aos processos de mutação gaussiana:

Listing 3: Extração e plotagem do ganho marginal evolutivo (Python).

```
1 def grafico_ganho_marginal(df_t: pd.DataFrame, df_r: pd.
   DataFrame, ax: plt.Axes) -> None:
```

```

2      """
3      """Grafico4--GanhoMarginal(DeltaMelhorAptidaoPorGeracao)
4      Revela os picos indicativos de descobertas de novas regioes
5      promissoras no espaco de busca.
6      """
7      for df, cor, nome in [(df_t, COR_TORNEIO, "Torneio"),
8                             (df_r, COR_ROLETA, "Roleta")]:
9          # Isolamento de ganhos estritamente positivos (elitismo
10             garante monotonia)
11          delta = df["melhor_aptidao"].diff().clip(lower=0)
12          delta_suave = suavizar(delta, janela=30)
13          ax.plot(df["geracao"], delta_suave, color=cor, lw=1.5,
14                  label=nome)
15          ax.fill_between(df["geracao"], 0, delta_suave, color=
16                          cor, alpha=0.15)

```

7.3 Protocolo de Análise Comparativa

Após a execução automatizada de 13 amostras independentes para mitigar os efeitos da aleatoriedade, as métricas médias consolidadas são apresentadas na Tabela 6.

Tabela 6: Métricas de comparação entre operadores de seleção (Média de 13 amostras independentes).

Métrica	Torneio Estocástico	Roleta Viciada
Melhor Aptidão Final (F_{best})	0,17009	0,16932
Geração de Convergência (g^*)	42	145
Gateways Ativos ($ G^* $)	5,0	5,0
Taxa de Cobertura (ρ_{cob})	100,0%	100,0%
Vida Útil Estimada (h)	120,8	120,3
Redundância Média (cam./sensor)	4,85	4,84
Tempo de CPU (ms)	~1350	~1350

7.4 Discussão dos *Trade-offs*

Os dados estatísticos das 13 amostras confirmam rigorosamente as premissas suportadas pela teoria. A **Seleção por Torneio Estocástico** ($k_T = 5$) obteve uma melhor aptidão ligeiramente superior (0,17009 contra 0,16932). O seu grande trunfo, no entanto, foi a sua notável velocidade de convergência computacional: o Torneio exigiu, em média, **apenas 42 gerações** para atingir 99% do seu limite ótimo, demonstrando maior robustez e conseguindo desviar-se dos mínimos locais originados pelas zonas de sombra de forma rápida [1].

A **Roleta Viciada**, por depender exclusivamente de probabilidade linear em relação à aptidão (*fitness proportionate*), necessitou de impressionantes **145 gerações** para convergir. O método patinou precocemente na estagnação populacional, perdendo capacidade exploratória inicial. Ambas as técnicas foram estritamente eficazes a garantir 100% da Cobertura de sensores exigida ($|G^*| = 5$), atestando a robustez geral da penalidade orçamental aplicada.

8 Aplicação Prática em Ambiente Industrial

8.1 Cenário: Manutenção Preditiva de Maquinário Pesado

O motor de otimização evolutivo construído tem utilidade direta e crítica na modelagem infraestrutural de **manutenção preditiva** da Indústria 4.0. Redes WSN instaladas em rolamentos e compressores monitoram correntes anômalas para prevenção de colapsos sistêmicos [2]. O motor substitui inteiramente as matrizes ineficientes de planejamento manual por processos algorítmicos autônomos escaláveis.

8.2 Fluxo de Implantação Prático

Etapa 1 — Levantamento Computacional: Mapeamento analítico de S e restrições. Zonas de sombra são convertidas no modelo matricial de recorte paramétrico e log-distância.

Etapa 2 — Compilação e *Deploy*: Inicialização do vetor de orçamentos e execução no *core* nativo em hardware padrão via `gcc -O2 -lm`.

Etapa 3 — Inteligência de Dados: Interpretação dos dados de cobertura ASCII exportados e execução de *scripts* analíticos (ex.: Matplotlib Python) para investigar fronteiras multiobjetivo viáveis.

Etapa 4 — Execução Física: Fixação paramétrica estrutural nas coordenadas $\{x^*, y^*, z^*\}$. Todos os protocolos de comunicação do ESP32 estarão validados sob teoremas de limite de banda -90 dBm preestabelecidos [2].

8.3 Escalabilidade

Para plantas expansivas com $n > 100$ e orçamentos substanciais de *gateways*, o limite computacional assintótico provado $O(G_{\max} \cdot N \cdot (\log N + n \cdot m))$ continua operante de forma eficiente, permitindo soluções na ordem de minutos usando unidades modernas de processamento de propósito geral [3].

9 Conclusão

Este trabalho apresentou o projeto e a arquitetura formal em linguagem C de um motor de otimização topológica focado em problemas reais de WSN e IIoT. O problema de determinação estrutural foi caracterizado como subjacente à classe NP-Completo do *Facility Location Problem*, exigindo a implantação de tratativas estocásticas para fuga de escalada exponencial computacional [3].

O desenvolvimento de algoritmos genéticos sob a representação híbrida genotípica recomendada em literatura [1] comprovou as evidências empíricas de simulação: é viável explorar de forma combinatória e contínua uma topologia física restritiva maximizando cobertura global, eficiência energética e redundância, operando sobre $M_{\max}$ orçamentário rígido.

Destaque analítico reside na verificação rigorosa de complexidade $O(G_{\max} \cdot N \cdot (\log N + n \cdot m))$, a qual comprova que instâncias em C99 executam o *pipeline* em tempo polinomial esperado superior a heurísticas simplificadas [3]. E sob os relatórios estatísticos de 13 amostras e métricas de ΔF , conclui-se formalmente ser a Seleção em Torneio o operador genético preferencial perante bloqueios de estagnação.

Como perspectivas futuras, vislumbra-se (i) integração aos vetores populacionais do NSGA-II visando isolamento rigoroso de frentes Pareto, e (ii) experimentação de RF de atenuadores estocásticos via *log-normal shadowing*.

Referências

- [1] C. Z. Janikow e D. Clair, “Simulating nature’s methods of evolving the best design solution,” *IEEE Potentials*, vol. 14, n. 1, pp. 13–17, fev./mar. 1995.
- [2] J. Li, L. L. H. Andrew, C. H. Foh, M. Zukerman e H.-H. Chen, “Connectivity, coverage and placement in wireless sensor networks,” *Sensors*, vol. 9, n. 10, pp. 7664–7693, out. 2009. DOI: 10.3390/s91007664.
- [3] T. H. Cormen, C. E. Leiserson, R. L. Rivest e C. Stein, *Introduction to Algorithms*, 3^a ed. Cambridge, MA, EUA: MIT Press, 2009.
- [4] R. W. Marks, “Multi-objective wireless sensor network deployment,” *Journal of Network and Computer Applications*, vol. 34, n. 1, pp. 61–76, jan. 2011. DOI: 10.1016/j.jnca.2010.04.008.